はじめに

1. データ分析によって、何を明らかにしたいのか。
2. 明らかにすることのために、どのデータ分析が必要なのか。
3. 必要なデータ分析のために、どんな形式のデータを用意する必要があるのか。

01. 相関分析

データに、どの程度の直線的関係があるかを検出する分析手法。回帰分析を行うか否かの判断材料になる。

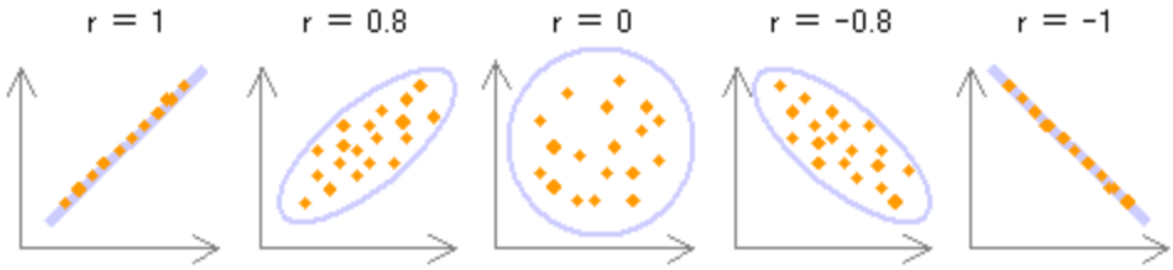

- **分析例**

```
# データを読み込む。
sample <- read.table("sample_edit.txt", header = T)


# 純広告とCV_純広告の散布図を作成。
g <- ggplot(sample, aes(x = 純広告, y = CV_純広告))
g <- g + geom
_point()
plot(g)


# 純広告とCV_純広告の相関分析を行う。
ts<-ts(sample[,2:5])
cor(ts, method = "pearson")


# 分析結果
                      純広告       リスティング   CV_純広告     CV_リスティング
# 純広告            1.00000000    0.5247992  0.1065025     -0.09415535
# リスティング       0.52479919    1.0000000 -0.2360605      0.20821230
# CV_純広告          0.10650249   -0.2360605  1.0000000      0.19500011
# CV_リスティング   -0.09415535    0.2082123  0.1950001      1.00000000
# // 純広告とCV_純広告の間には、弱い直線的関係がある。
```

02-01. 線形回帰分析

因果関係がありそうなデータに対して、横軸を原因、また縦軸を結果とし、最も当てはまりの良い線形モデルを推定する分析手法。モデルの精度が高ければ因果関係の証明になり、またモデルに原因を代入することで結果を予測できる。

◆ 単回帰分析

原因と結果が一つずつと仮定した時に、最も当てはまりの良い線形モデルを推定できる。

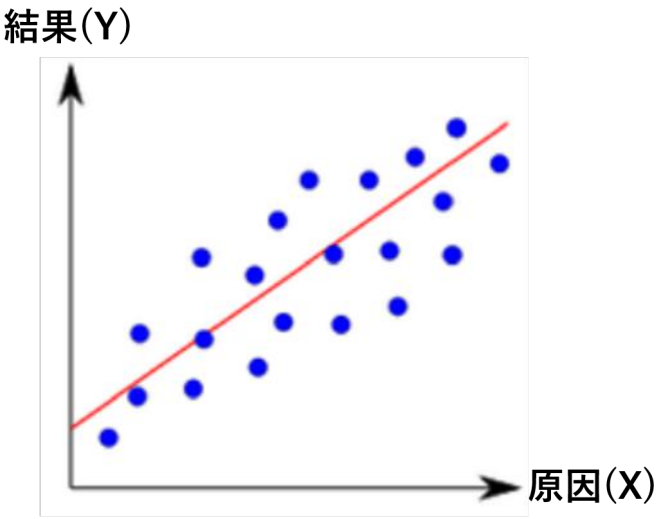

- **回帰方程式**

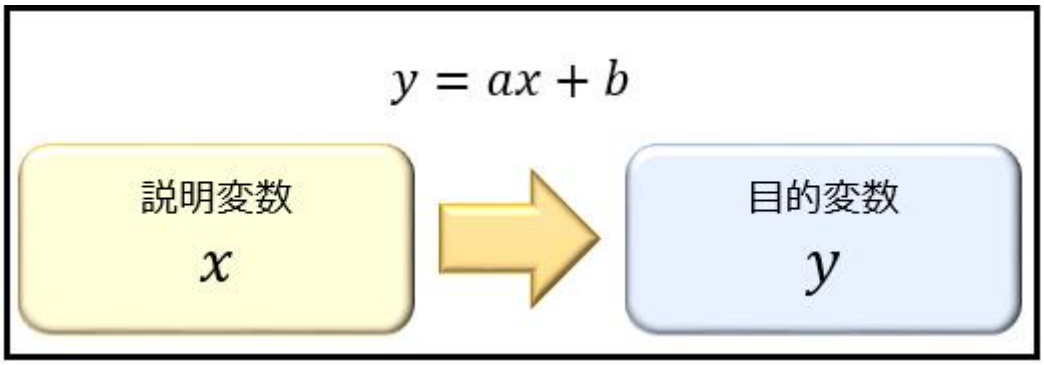

- **分析例**

```
# データを読み込む。
sample <- read.table("sample_edit.txt", header = T)
ts <- ts(sample[,2:5])


# データ型を変更。
df <- data.frame(ts)


# CV_純広告と純広告に基づく線形回帰分析を行う。
Reg <- lm(CV_純広告 ~ 純広告,df)


# 分析結果
summary(Reg)


# Coefficients:
#              Estimate Std. Error t value Pr(>|t|)
```

```
# (Intercept) 1.099e+01  2.405e+00   4.571 3.11e-05 ***
# 純広告       2.239e-05  2.927e-05   0.765    0.448
# // 純広告の回帰係数のp値 > 0.05 より、因果関係がない可能性。
```

◆ 重回帰分析

原因が二つ以上で結果が一つと仮定した時に、最も当てはまりの良い線形モデルを推定できる。ただし、グラフでは、モデルは平面で表される。

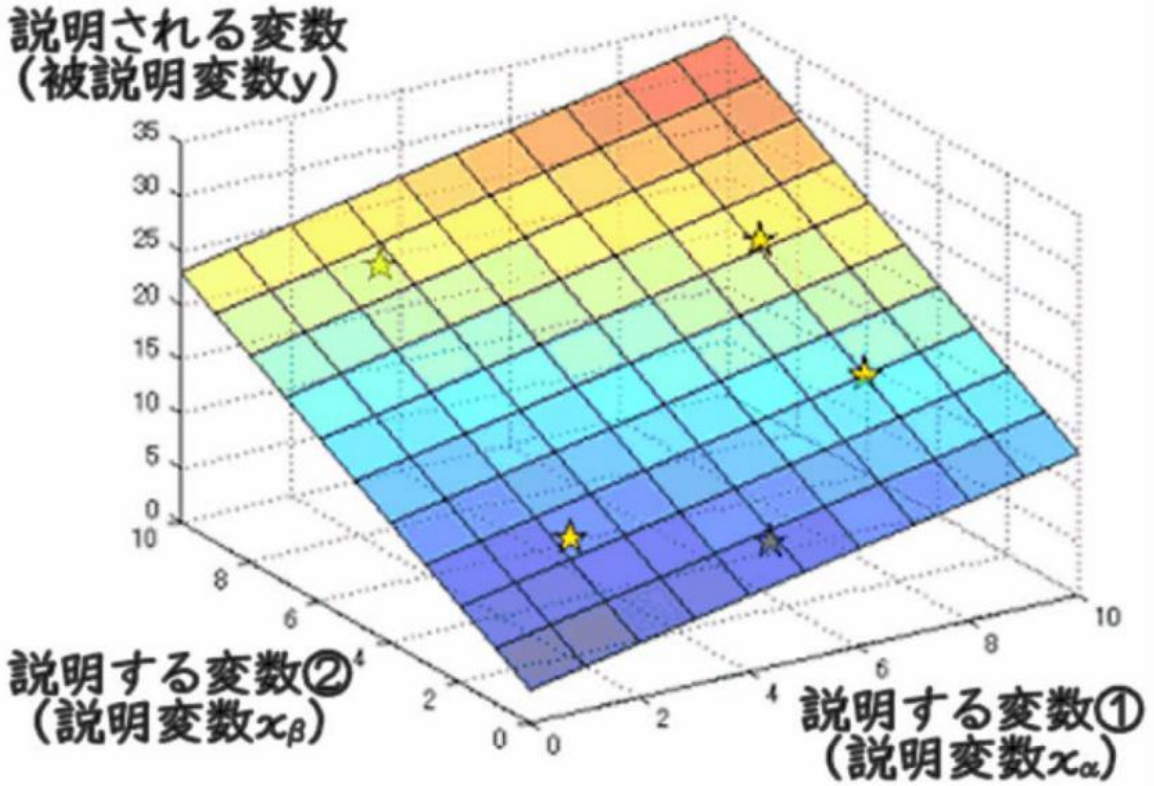

- **回帰方程式**

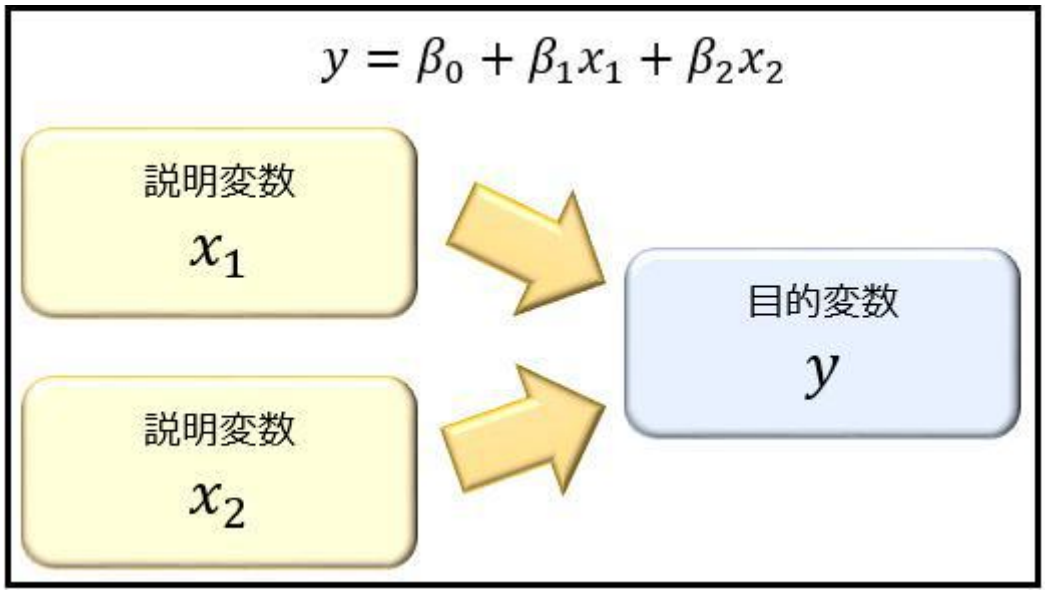

- **分析例**

```
# データを読み込む。
sample <- read.table("sample_edit.txt", header = T)
```

```r
days <- weekdays(as.Date(sample$DATE))
sample1<-transform(sample,days=days)

library(caret)

# 曜日をダミー変数に変換
tmp <- dummyVars(~days, data=sample1)
days1 <- as.data.frame(predict(tmp, sample1))


# 曜日の順番を整形
days2 <- days1 [ c(3,1,4,7,2,5,6) ]


# 広告データと曜日データを結合
ts1 <- cbind(sample, days2)


# データ型を変更
df <- data.frame(ts1)


# 重回帰分析を行う。
Reg<-lm(CV_純広告 ~ days.月曜日+days.火曜日+days.水曜日+days.木曜日+days.金曜日,df)


# 分析結果
summary(Reg)


# Coefficients:
#             Estimate Std. Error t value Pr(>|t|)
# (Intercept)    8.857      1.007   8.797 1.69e-11 ***
# days.月曜日     5.286      1.744   3.031 0.003957 **
# days.火曜日     4.893      1.670   2.930 0.005212 **
# days.水曜日     6.143      1.670   3.679 0.000601 ***
# days.木曜日     5.893      1.670   3.529 0.000944 ***
# days.金曜日     4.393      1.670   2.631 0.011479 *
# // 月、水、金の回帰係数のp値 < 0.05 より、月水金で因果関係があり、火金で因果関係がない可能性。
```

02-02. 非線形回帰分析

因果関係がありそうなデータに対して、横軸を原因、また縦軸を結果とし、最も当てはまりの良い非線形モデルを推定する分析手法。モデルの精度が高ければ因果関係の証明になり、またモデルに原因を代入することで結果を予測できる。非線形モデルを推定するためには、モデルを一般化し、一般化線形モデルとして処理する必要がある。

◆ ロジスティック回帰分析

説明変数が質的変数の場合に、最も当てはまりの良い非線形モデル（ロジスティック分布）を推定する。

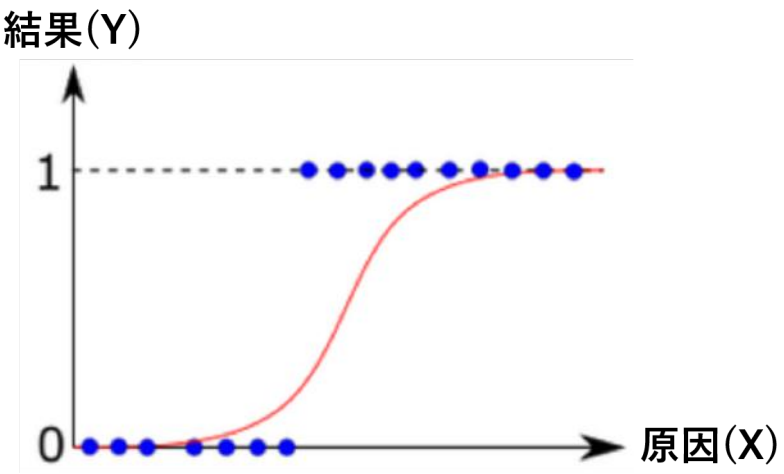

- **回帰方程式**

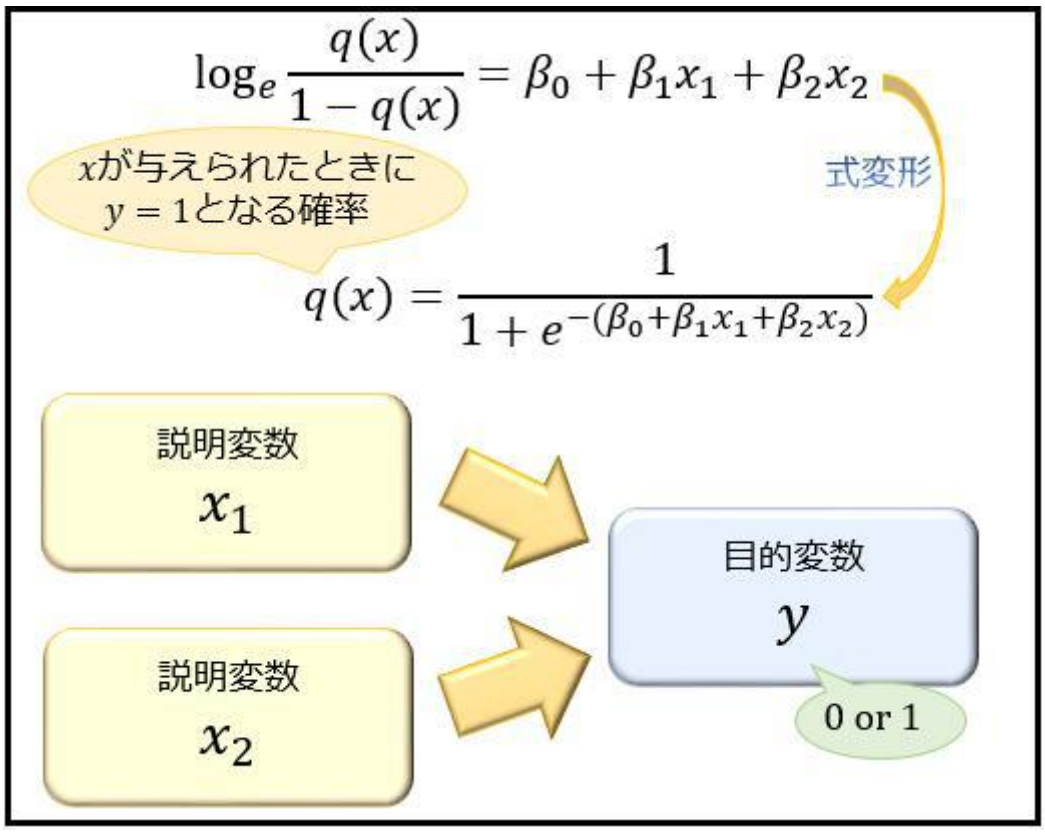

- **分析例**

```
# データを読み込む。
sample<-read.csv("CV_data2.csv",header=T)


# リンク関数をロジットとし、非線形モデルを一般化する。
result_lg = glm(CP申込み ~ 性別+経済関連, sample, family=binomial)


# オッズ比を出力
exp(result_lg2$coefficients)


# オッズ比の出力結果
# (Intercept)         性別      経済関連
```

```
# 0.08930881 14.98017457  1.75649720
```

03. 決定木分析

データに対して、最も当てはまりの良い決定木モデルを推定する分析手法。

◆ 分類木分析

決定木モデルを分類モデルとして用いる場合の決定木分析。

- **図解例**

赤い点：被験者が暑いと感じた日

青い点：被験者が暑くないと感じた日

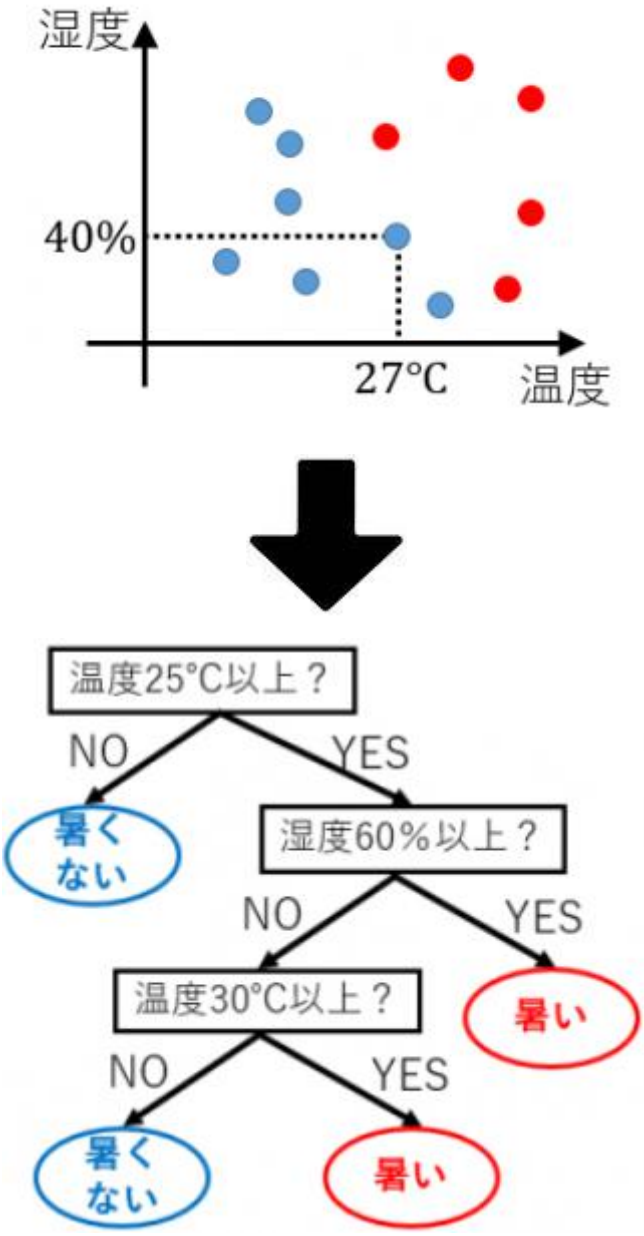

- **分析例**

```
# データを読み込む。
sample <- read.csv("CV_data.csv", header = T)
```

```
# 識別値のidを説明変数から除いたうえで、決定木を構築。
library(rpart)
tree <- rpart(CV~AGE + SEX + AD, data = sample)


# partykitパッケージで決定木をグラフ化。
library(partykit)
plot(as.party(tree), tp_args = T)


# rattleとrpart.plotパッケージで決定木をグラフ化。
library(rattle)
library(rpart.plot)
fancyRpartPlot(tree)
```

04. 階層クラスタ分析

データを、似ている順に階層的にグループ化（クラスタリング）していく分析手法。データ間の同一性を明らかにすることができる。

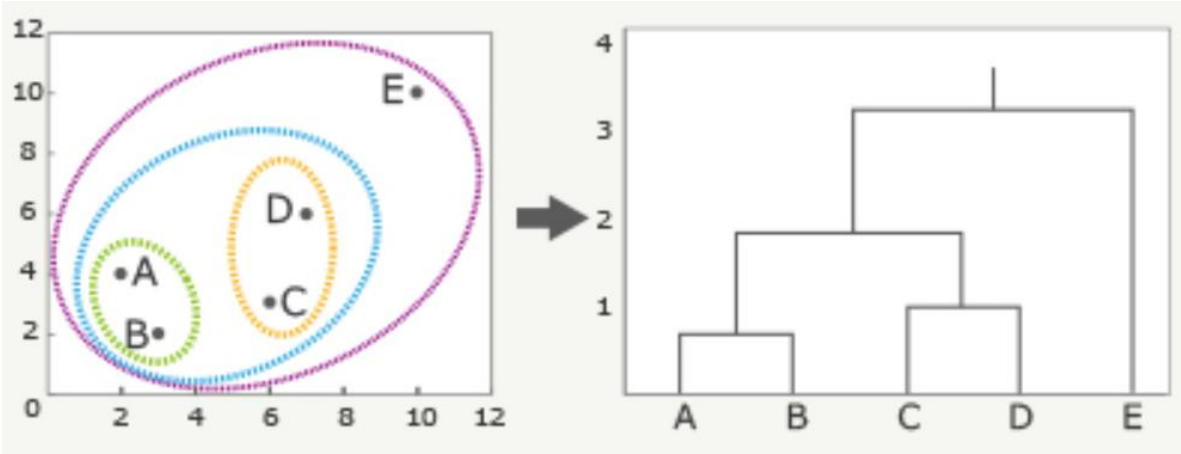

- **分析例**

```
# データを読み込む。
sample1 <- read.csv("CV_data.csv")


# ダミー変数に変換するために必要な情報が格納されたリストを生成。
library(caret)
tmp  <-  dummyVars(~.,  data = sample1)


# リストを基に、sample1の質的変数をダミー変数に変換。
sample1.dummy  <-  as.data.frame(predict(tmp,  sample1))


# id以外の列を標準化。
scale.dummy <- scale(sample1.dummy[, 2:9])
```

```r
# 距離行列を計算。
d1 <- dist(scale.dummy)


# ウォード法による階層クラスター解析を行い、グラフ化。
cluster1 <- hclust(d1, method = "ward.D2")
plot(cluster1)
```

05. 関数の解説

◆ `ggplot()`

1. `ggplot()`：グラフのキャンバスを準備
2. `geom_XXX()`：グラフをプロット
3. `theme()`：グラフを追加加工